大模型与AIGC概述

陈会

目录

CONTENTS

1 大模型是什么

大模型是什么

引爆AI圈

- 2022年11月底，OpenAI发布ChatGPT聊天应用
- 2023年1月份，ChatGPT活跃用户数突破1亿，AI圈和非AI圈被彻底引爆
- 2023年1月至今，全球各大科技公司纷纷推出自己的大模型（“万模大战”）

万字科普GPT4为何会颠覆现有工作流： https://www.bilibili.com/video/BV1MY4y1R7EN/?vd_source=1f9d080a948e6fa251ab83b0c49fa6fd

大模型是什么

初步感受大模型的魅力（https://tongyi.aliyun.com/qianwen/）

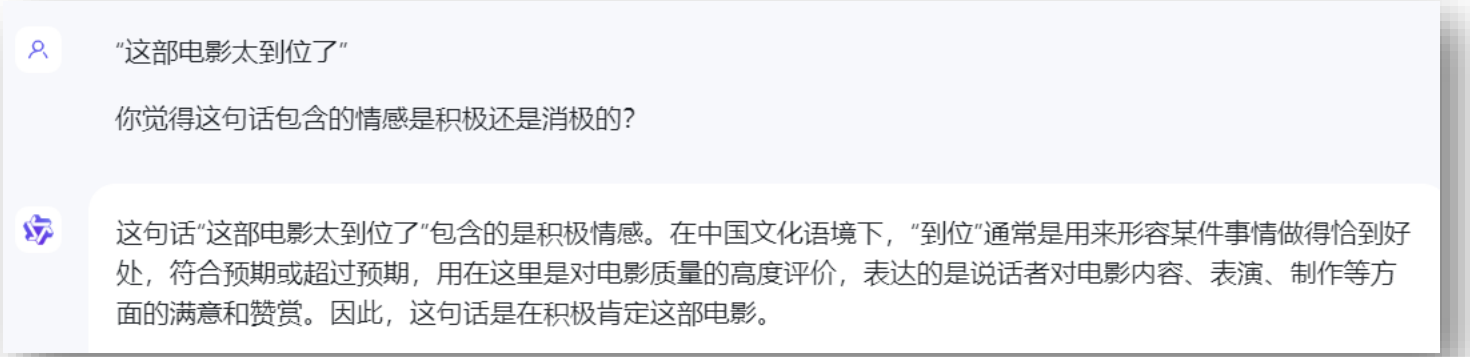

大模型是什么

大模型是什么

起源：大语言模型（Large Language Models， LLMs），围绕自然语言处理任务而创建的一系列模型。

发展：**基础模型（Foundation Models）**，可以处理多模态数据，不局限于自然语言。

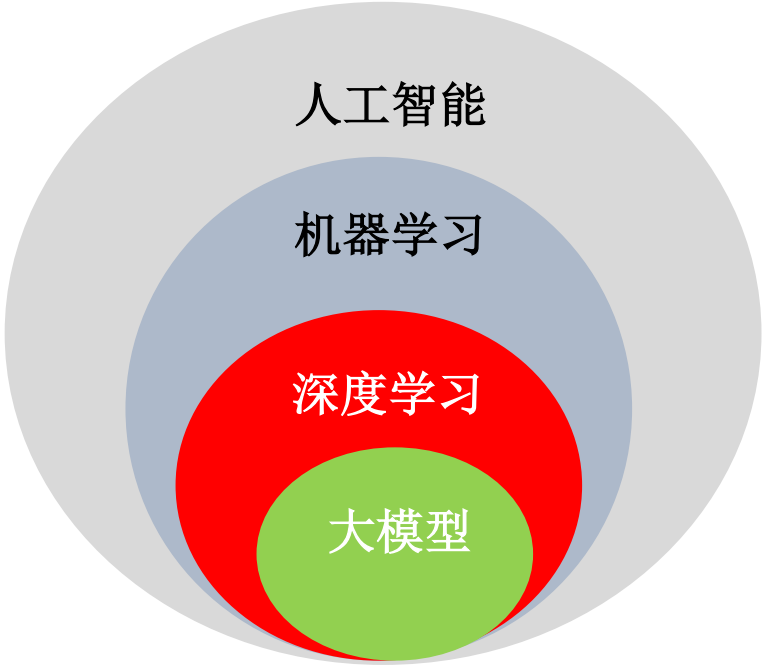

大模型是什么

关于大模型的定义

定义1：是一种由包含数百亿以上参数的深度神经网络构建的语言模型，通常使用自监督学习方法，通过大量无标注文本进行训练。

定义2：任意的在大规模数据上训练并且可以适配（例如，微调）广泛下游任务的模型。

参考：《大规模语言模型从理论到实践》《On the Opportunities and Risks of Foundation Models》

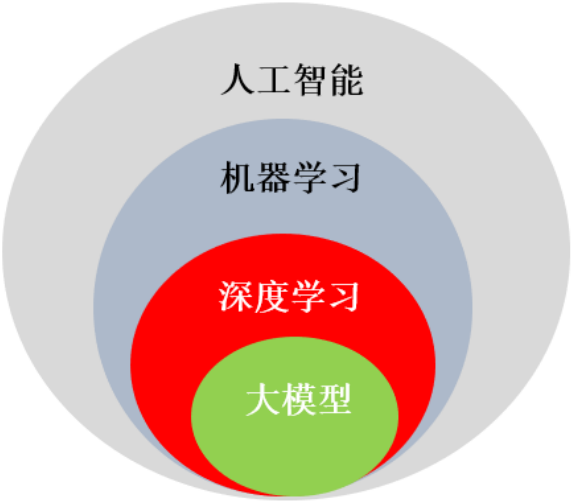

大模型是什么

大模型的特性

1. 大规模参数量，超过百亿参数规模的神经网络模型。
2. 大规模训练数据，通过海量数据进行自监督预训练。
3. 涌现能力，表现了人类才会有的智能（上下文学习、思维链）。
4. **多模态数据多领域适应性（通用人工智能，AGI），经适当微调或提示，能应用于不同领域，且效果显著**
5. 超长上下文感知，基于Transformer的注意力机制保证其能充分理解信息，并做出合理推断。
6. 不是搜索引擎，无法感知实时数据。

“大语言模型研究进展之快，即便是在自然语言处理领域开展了 近三十年工作的我们也难以适从。”—复旦大学张奇

大模型是什么

典型代表（国外）

1. GPT系列：https://chat.openai.com/
2. 谷歌gemini：https://gemini.google.com/
3. 微软Copilot：https://www.bing.com/chat
4. Meta的Llama：https://llama.meta.com/llama2
5. Claude系列：https://claude.ai
6. XAI的grok：https://x.ai
7. Mistral AI：https://mistralai7b.com/

大模型是什么

典型代表（国内）

1. 通义千问：https://tongyi.aliyun.com/qianwen/
2. 文心一言：https://yiyan.baidu.com/welcome
3. 智谱清言：https://chatglm.cn/main/detail
4. 百川大模型：https://www.baichuan-ai.com/home
5. 豆包：https://www.doubao.com/
6. 讯飞星火：https://xinghuo.xfyun.cn/
7. 天工：https://www.tiangong.cn/
8. 商汤商量：https://chat.sensetime.com/wb/login
9. 腾讯混元大模型：https://hunyuan.tencent.com/?ref=feizhuke.com
10. Kimi：https://kimi.moonshot.cn/
11. 华为盘古大模型（需提前申请）：https://www.huaweicloud.com/product/pangu.html
12. 360智脑：https://chat.360.com/?src=ai_360_com

大模型是什么

大模型能做什么

1. 文本生成：问题回答、文稿撰写、代码生成、数学解题。
2. 智能客服：包括通用聊天机器人和基于RAG技术的垂直领域机器人。
3. 机器翻译：生成目标语言的高质量译文。
4. 文本摘要：对于长篇文章或报告，模型可以提炼关键信息生成简洁的摘要。
5. 情感分析：分析文本中的情感色彩，判断作者的态度是正面、负面还是中立。
6. 视觉任务：文生图、文生视频、看图说话等

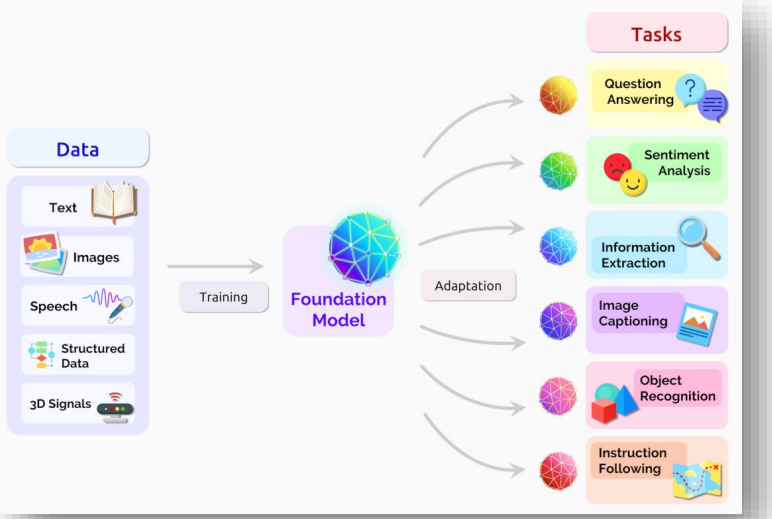

目录

CONTENTS

1 大模型是什么

2 大模型的前世今生

大模型的前世今生

从神经网络到大模型

1. 单层感知机（解决线性可分问题，20世纪40年代）
2. BP传播算法（解决线性不可分问题，20世纪80年代）
3. 深度神经网络（海量图片分类，2010年左右）
4. 大模型/基础模型（通用人工智能，2020年左右）

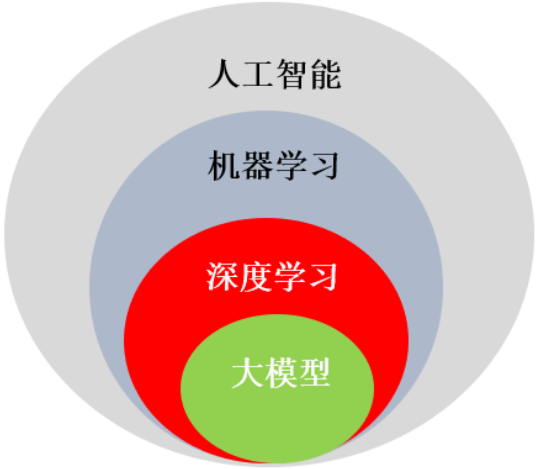

大模型的前世今生

大语言模型的三个发展阶段 *《大规模语言模型从理论到实践》*

1. **基础模型阶段**主要集中在2018年至2021年期间，期间发布了一系列代表性的大语言模型，如BERT、GPT、百度ERNIE、华为盘古-α、Palm等。这些模型的发布为大语言模型的研究打下了基础。
2. **能力探索阶段**主要发生在2019年至2022年期间。研究人员开始尝试指令微调（Instruction Tuning）方案，将各种类型的任务统一为生成式自然语言理解框架，并使用构造的训练语料对模型进行微调。
3. **突破发展阶段**以2022年11月ChatGPT的发布为起点。ChatGPT通过一个简单的对话框，利用一个大语言模型就能够实现问题回答、文稿撰写、代码生成、数学解题等多种任务

目录

CONTENTS

1 大模型是什么

2 大模型的前世今生

3 大模型爆火的原因

大模型爆火的原因

原因一 能通过图灵测试

让人们看到了通用人工智能乃至强人工智能的希望

- 功能极其强大，远超同期其他模型
- 可以完成跨领域、跨模态任务

图灵测试：

测试者（人）与被测试者（机器）隔开

测试者通过一些装置（如键盘）向被测试者随意提问

测试者根据所接受回答判定对方是人或机器

多次测试后平均每个测试者做出超过30%的误判（将机器判定成人）

这台机器就被认为具有人类智能

它不仅可以进行日常对话，还能够完成复杂任务，如撰写文章、回答问题等。令人惊讶的是，所有这些任务都由一个模型完成。在许多任务上，ChatGPT的性能甚至超过了针对单一任务进行训练的有监督算法。这对于人工智能领 域具有重大意义。

——《大规模语言模型从理论到实践》

大模型爆火的原因

原因二 极具争议的AI觉醒

“ChatGPT是我一生中见到的两项最具革命性技术之一”——比尔盖茨

“AI将是人类未来文明的最大风险之一”——埃隆·马斯克

“AI是谷歌正在开发的最深奥的技术”——谷歌CEO桑达尔•皮查伊

“AI将颠覆社会”——巴菲特

大模型爆火的原因

原因三 使用方式极其简单

在对话框中提出你的需求即可，ChatGPT活跃用户数一个月内就破亿。

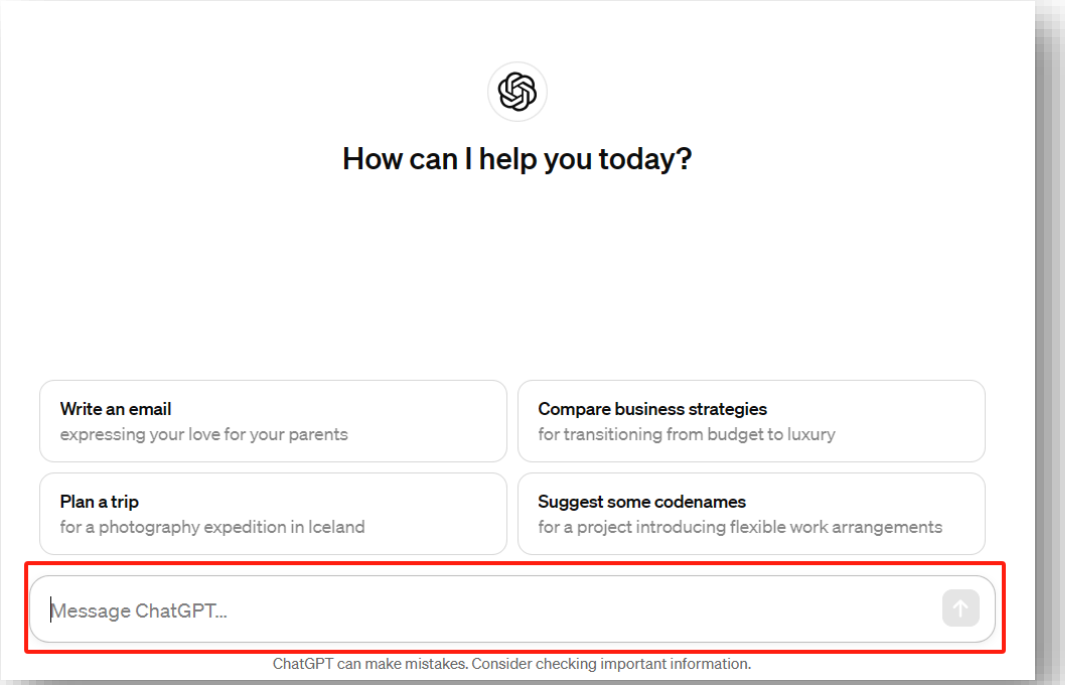

目录

CONTENTS

1 大模型是什么

2 大模型的前世今生

3 大模型爆火的原因

4 大模型原理介绍

大模型原理介绍

GPT（生成式模型）的工作过程：单字接龙

模型输入：*我们*

模型输出：*发明了一个新的和简单的模型*

文本生成的过程本质就是单字接龙。

思考：单字接龙为什么可以产生这么大的威力？

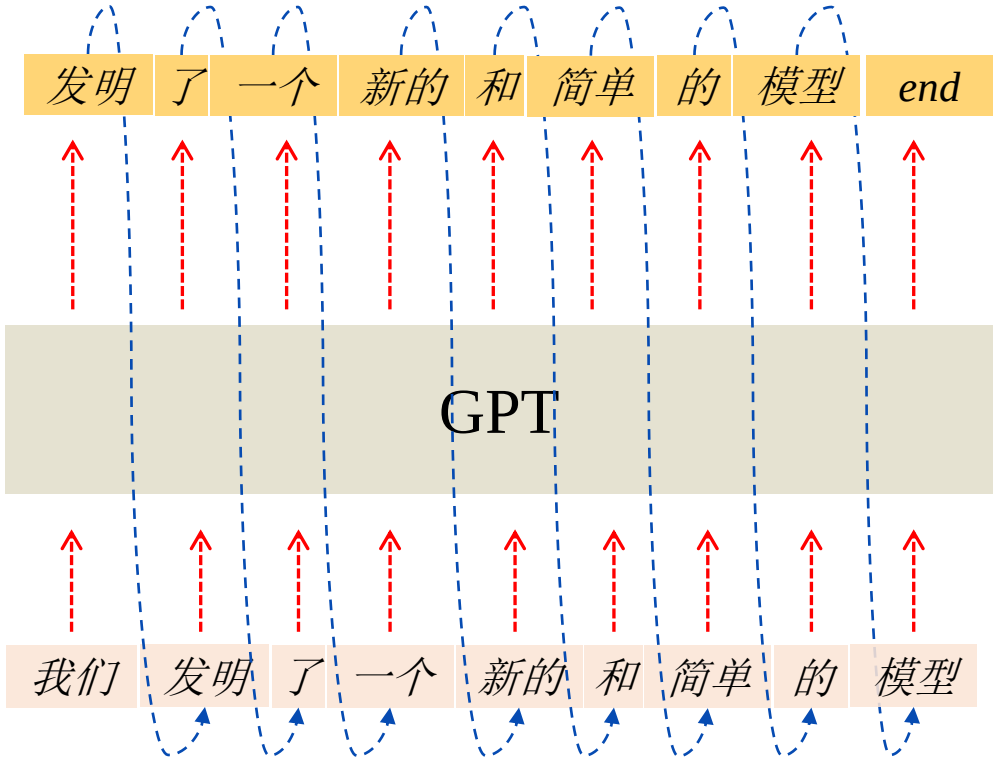

大模型原理介绍

ChatGPT构建流程

ChatGPT构建的四个阶段：预训练、有监督微调、奖励建模、强化学习。

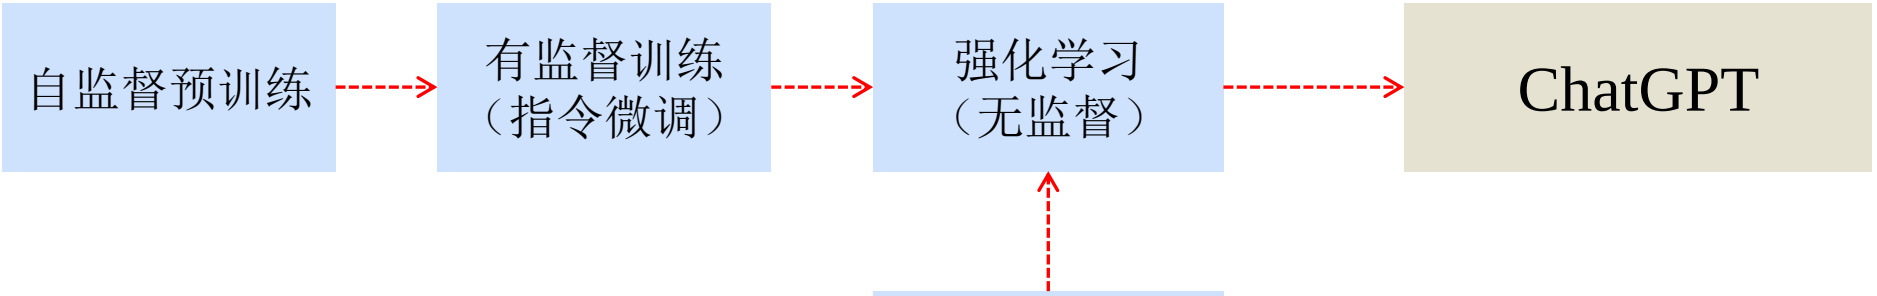

	预训练	有监督微调	奖励建模	强化学习
数据集合	原始数据 数千亿单词：图书、百科、网页等	标注用户指令 数万用户指令和对应的答案	标注对比对 百万量级标注对比对	用户指令 十万量级用户指令
算法	语言模型训练	语言模型训练	二分类模型	强化学习方法
模型	基础模型	SFT 模型	RM 模型	RL 模型
资源需求	1000+GPU 月级别训练时间	1-100GPU 天级别训练时间	1-100GPU 天级别训练时间	1-100GPU 天级别训练时间

大模型原理介绍

token是什么

在模型中被处理的数据单元并不是单词/词语，而是token。

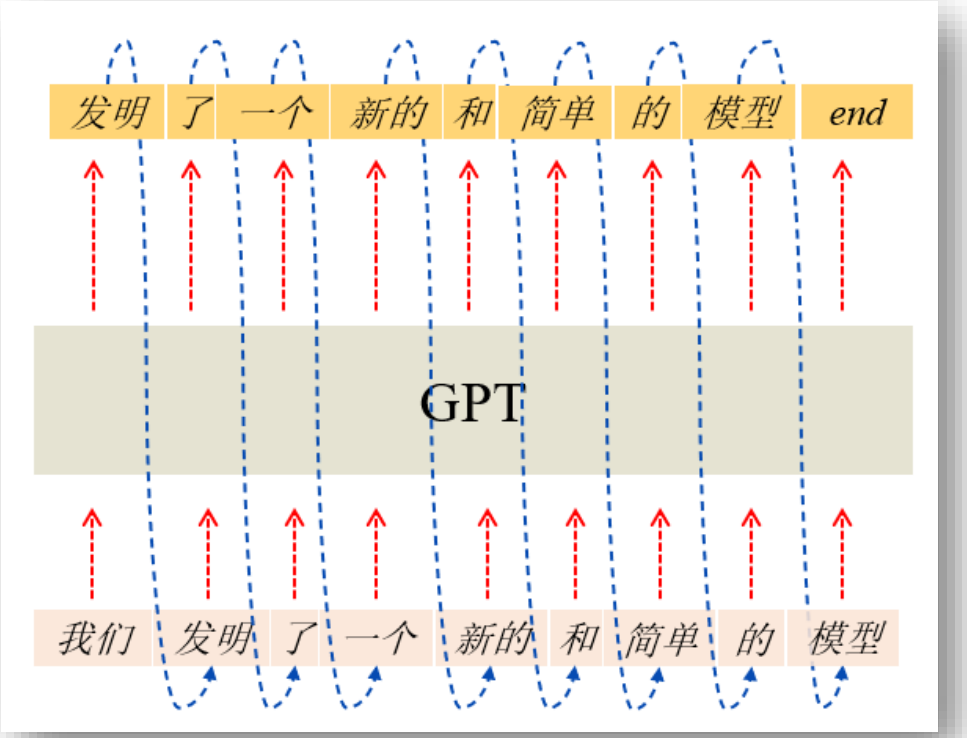

大模型原理介绍

token是什么

token是文本处理过程中的基本单元，通常是指一个单词、标点符号或者是由空格分隔的文本片段。

token是大模型世界中的“单词”，所有文本都可以由token组合而来。

原始文本：Many words map to one token, but some don't: indivisible.

Token序列：Many words map to one token, but some don't: indivisible.

原始文本：大多数单词对应一个token，但也有些例外。

Token序列：大多数单 对应一个token，但也有些例外。

大模型原理介绍

token是什么

英文语料中1个token约有4个英文字母，100个token约等于75个单词的长度。

中文里1个token绝大部分情况对应1~2个字，1个字居多。

大模型的token字典一般跨语种，字典中token数量为十万量级。

原始文本：Many words map to one token, but some don't: indivisible.

Token序列：Many words map to one token, but some don't: indivisible.

原始文本：大多数单词对应一个token，但也有些例外。

Token序列：大多数单 对应一个token，但也有些例外。

大模型原理介绍

token是什么

token从海量语料中统计而来，有不同的统计方法，其一般由高频词和低频词的子词组成。

token要保留原始文本中单词间的语义关系。

尽可能避免出现未登录词（OOV），但字典又不能太大。

原始文本：Many words map to one token, but some don't: indivisible.

Token序列：Many words map to one token, but some don't: indivisible.

原始文本：大多数单词对应一个token，但也有些例外。

Token序列：大多数单对应一个token，但也有些例外。

目录

CONTENTS

1 大模型是什么

2 大模型的前世今生

3 大模型爆火的原因

4 大模型原理介绍

5 AIGC简介

AIGC简介

AIGC是什么

AIGC（Artificial Intelligence Generated Content）是指利用人工智能技术来生成**全新的**、**逼真的**、**有用的**数据，如文本、图像、音频和视频等，可以在一定程度上模仿人类的创造力和写作风格。

在此之前的内容生成方式主要为：

1. PGC（Professional Generated Content），专家生产内容，如图书、报纸、期刊等。
2. UGC（User Generated Content），用户生产内容，如微博、公众号、自媒体等。

AIGC简介

AIGC与大模型的关系

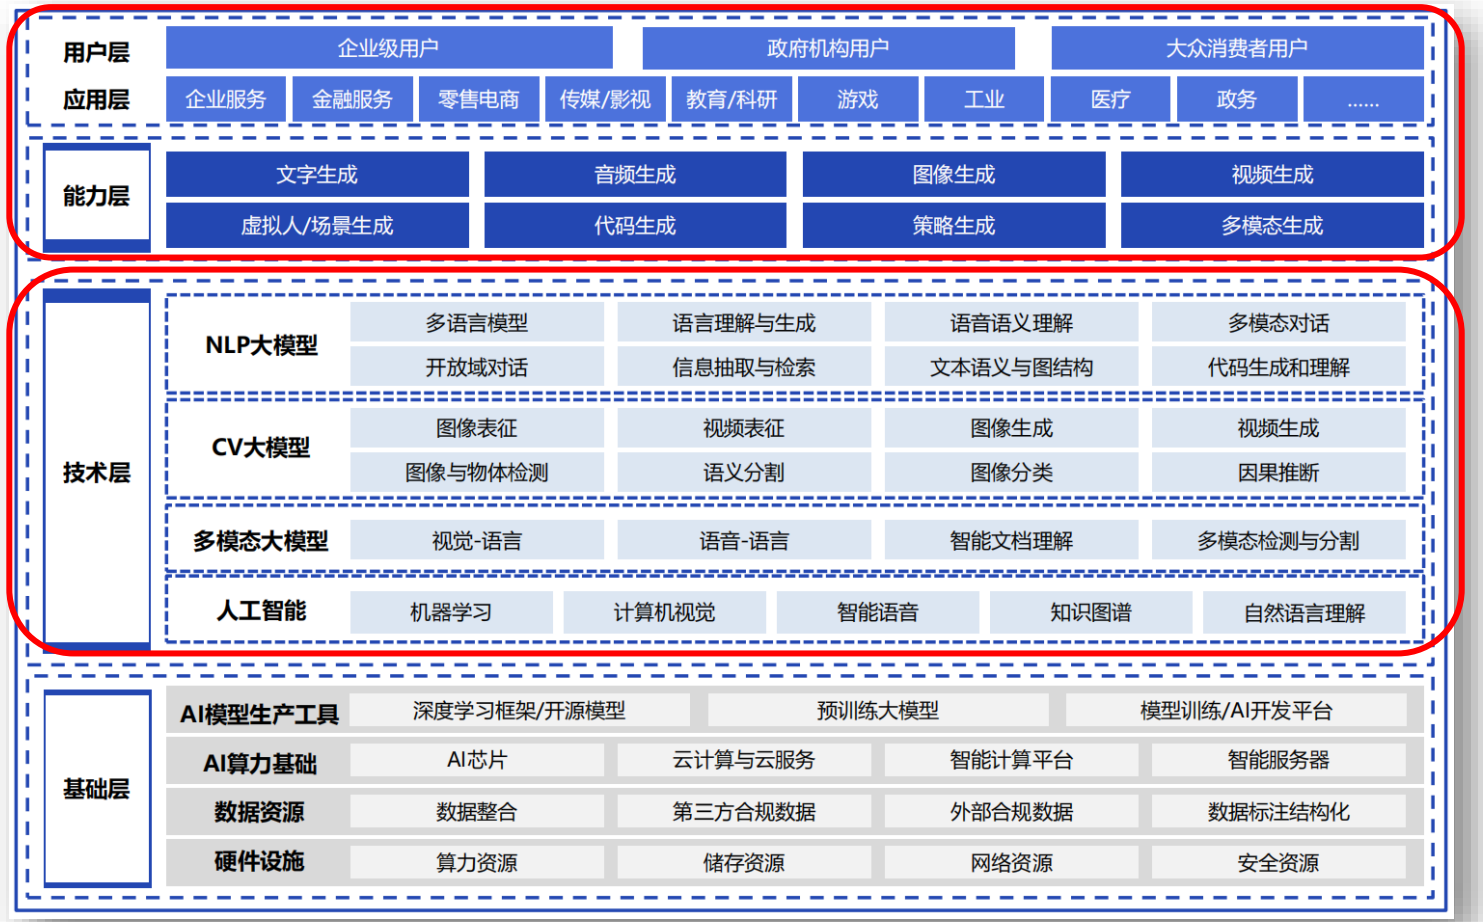

AIGC

大模型

AIGC简介

AIGC与大模型的关系

1. **大模型为AIGC提供了强大的生成能力：**由于大模型具有强大的学习能力和理解能力，因此可以生成更加丰富、多样和高质量的内容，从而推动AIGC的发展。
2. **AIGC为大模型提供了丰富的应用场景：**大模型在AIGC领域的应用非常广泛，包括文本生成、图像生成、音乐创作等。这些应用场景不仅展示了大模型的强大能力，也为大模型的研究和发展提供了实际的需求和动力。
3. **AIGC与大模型协同进化：**随着AIGC应用的不断深入，对大模型的需求也在不断提高，这将推动大模型不断进行技术优化和创新。同时，大模型的进步也将进一步推动AIGC的发展，两者形成了一种协同进化的关系。

目录

CONTENTS

1 大模型是什么

2 大模型的前世今生

3 大模型爆火的原因

4 大模型原理介绍

5 AIGC简介

6 模型

基础模型（大模型）简介

大模型工作机制

1. 大规模数据集预训练（Pre-training）
2. 下游任务（downstream）适配

注意：适配并不局限于微调（Fine-tuning），提示（prompt）也是一种重要手段。

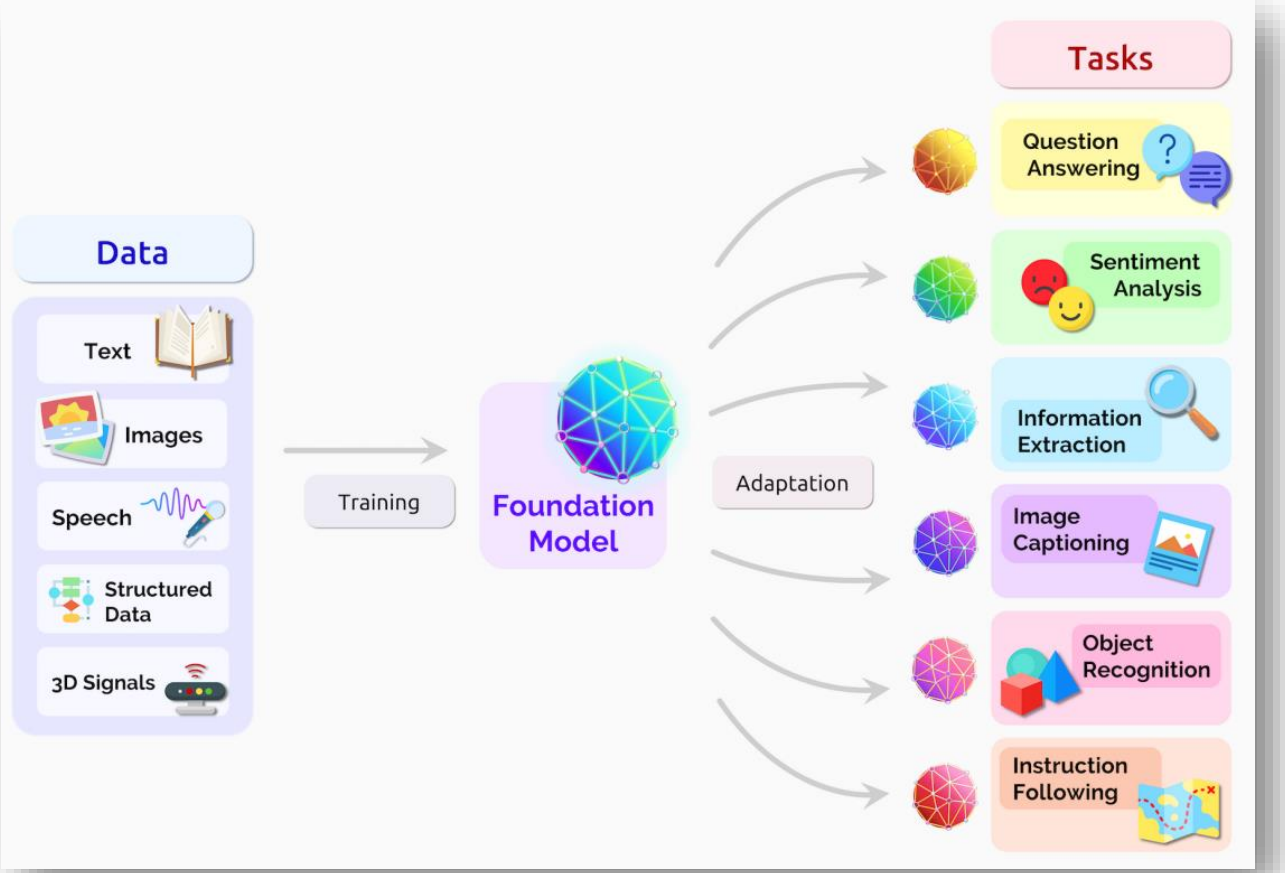

模型选择

如何选择预训练模型？

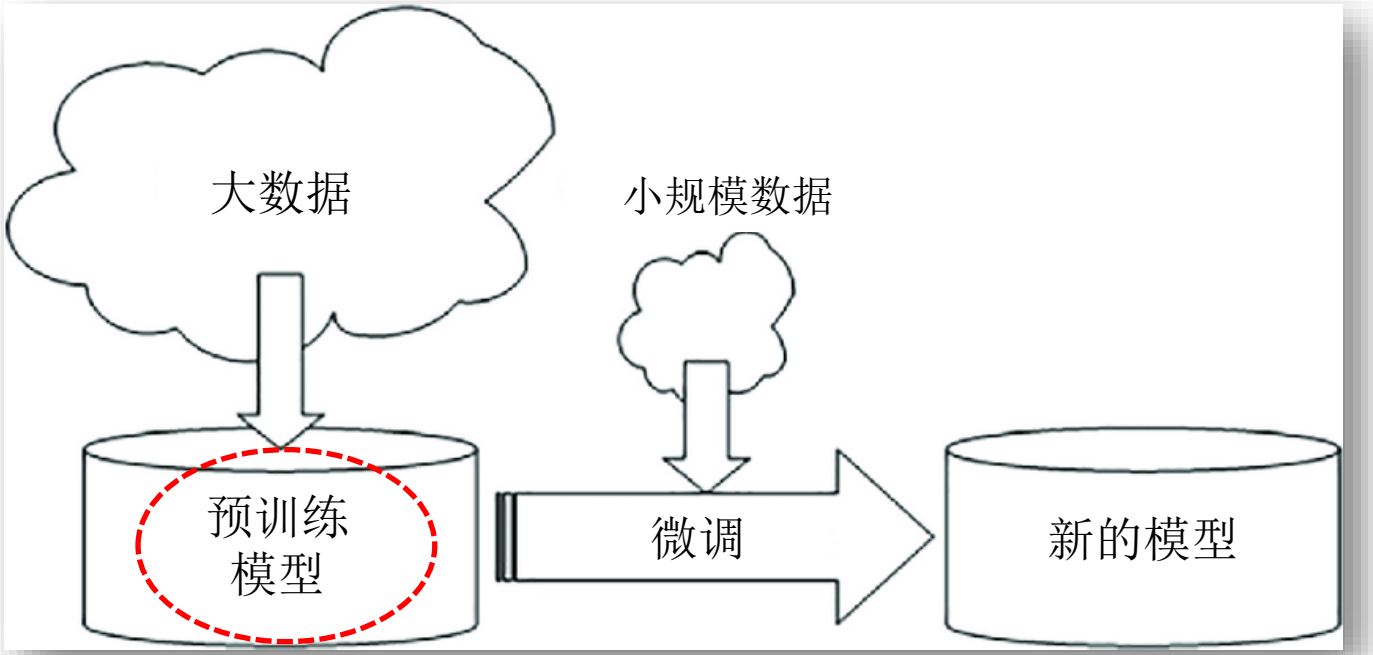

万模基座Transformer

Transformer引入

1. 不要RNN，也不要CNN，只需要注意力机制
2. 由Encoder与Decoder两部分组成
3. Decoder端引入自回归机制

利用transformer完成机器翻译：

- Encoder接收源语言作为输入
- Decoder生成目标语言作为输出

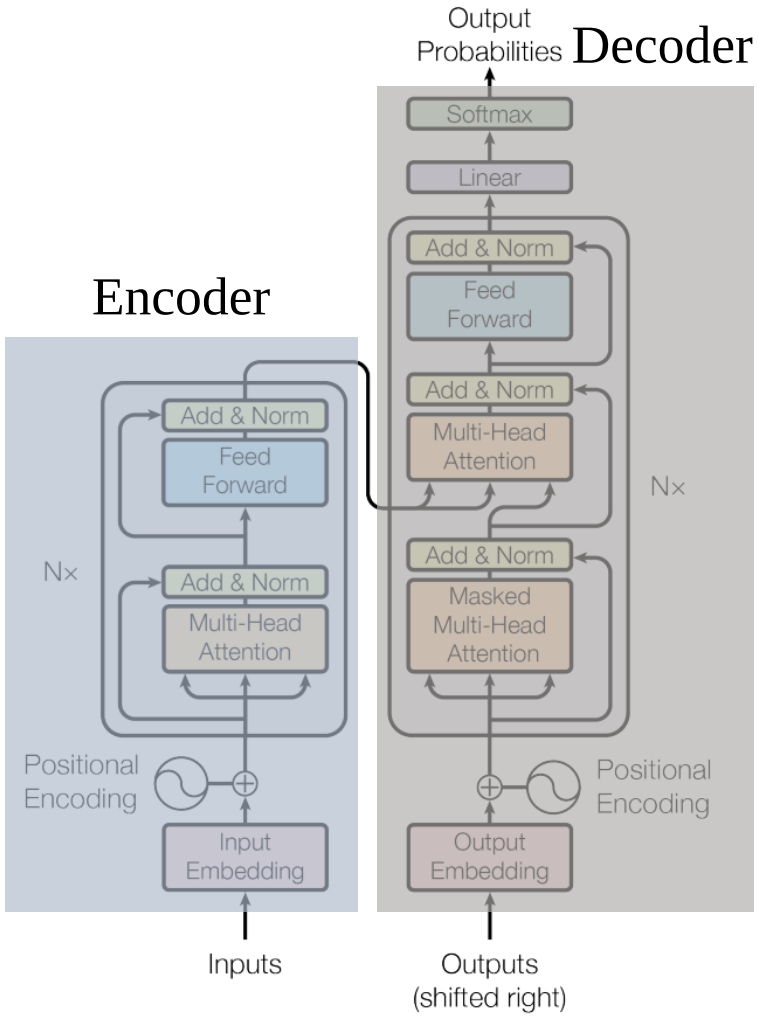

万模基座Transformer

Transformer整体计算流程（训练阶段）

X: We propose a new simple network architecture.

y: 我们提出了一个全新且简明的网络结构.

注意：针对每次输出，都会计算其与目标值间损失值的梯度项，以便对模型参数进行更新。

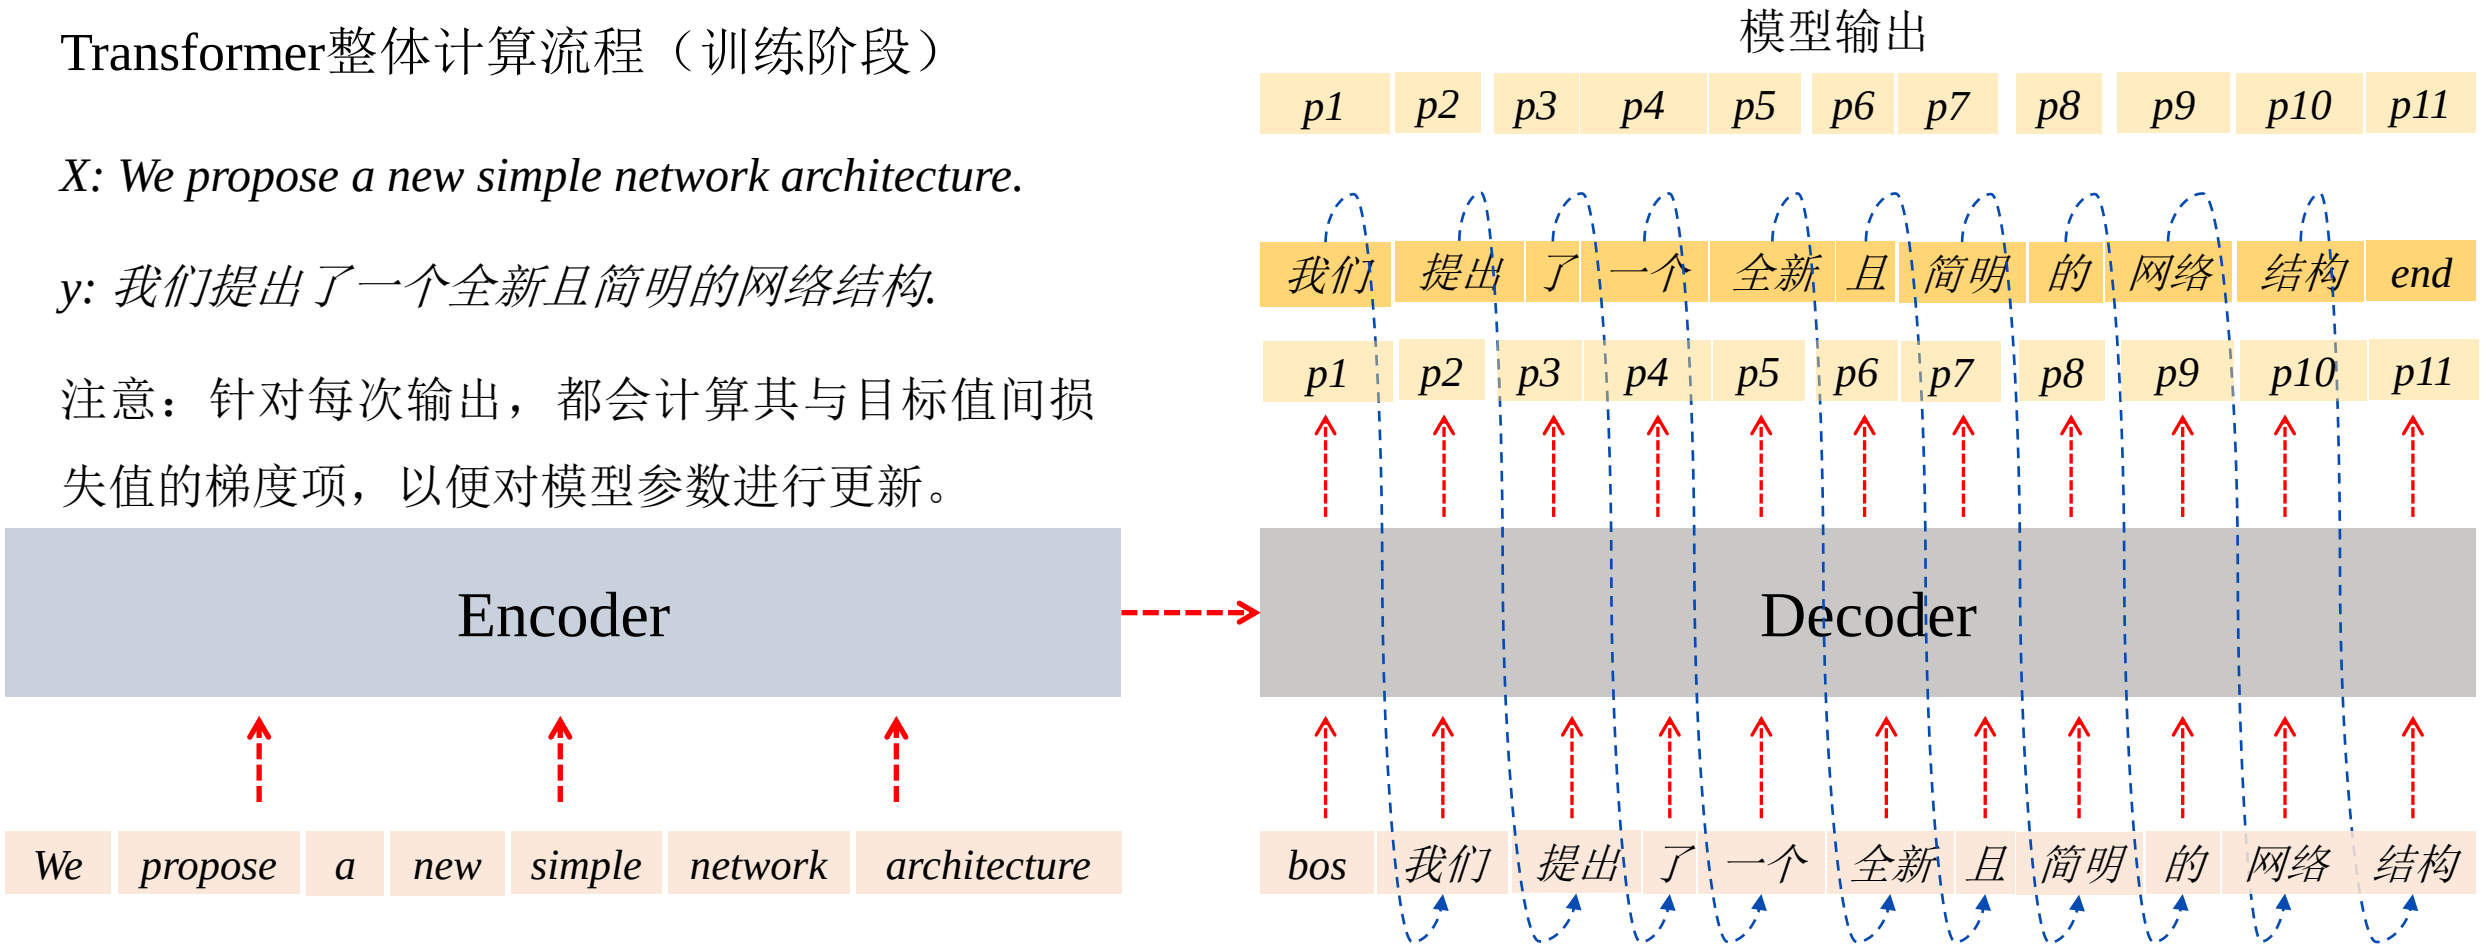

Transformer应用

Huggingface介绍

- Huggingface（https://huggingface.co）是一家在NLP社区做出杰出贡献的纽约创业公司，其所提供的大量预训练模型和代码等资源被广泛的应用于学术研究当中。
- Huggingface发布的 ***Transformers*** 提供了数以千计针对于各种任务的预训练模型，开发者可以根据自身的需要，选择模型进行训练或微调，也可阅读api文档和源码， 快速开发新模型。
- 支持 100 多种语言的文本分类、信息抽取、问答、摘要、翻译、文本生成。
- 它的宗旨是让最先进的 NLP 技术人人易用。
- 安装：pip install transformers

Transformers

数据准备

使用Tokenizer进行预处理

- 分词器（Tokenizer）简单点说就是将字符序列转化为数字序列，对应模型的输入。

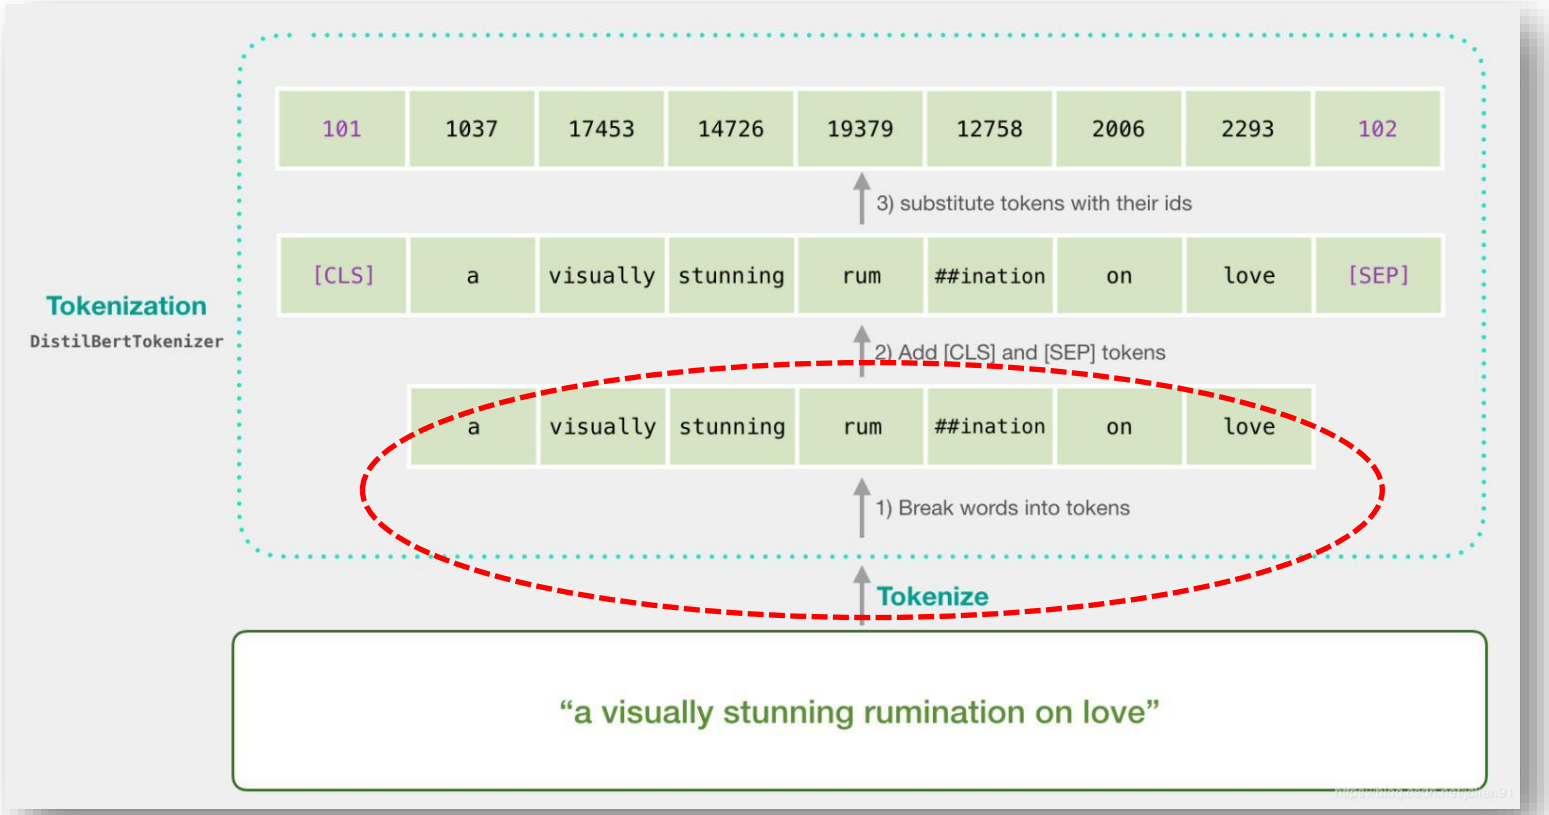

什么是大模型微调（Fine Tuning）

什么是大模型微调？

大模型微调（Fine-tuning）是指**在已经预训练好的大型语言模型基础上，使用特定的数据集进行进一步的训练，**以使模型适应特定任务或领域。

其根本原理在于，模型只能够代表它所接收到的数据集的逻辑和理解，而对于新数据样本，其并不能很好地识别/理解，且对于大模型而言，也无法很好地解决特定场景下的问题。

以BERT模型为代表的**“预训练语言模型 + 下游任务微调”**模式成为了自然语言处理研究和应用的新范式。

所需的**微调量取决于模型大小、任务的复杂性和数据集的大小**。

什么是大模型微调（Fine Tuning）

什么是大模型微调？

直观理解，微调其实就是改变已有模型的权重参数。

可以微调全部参数，也可以是部分参数。

可以微调输入层，也可以是中间层、输出层等。

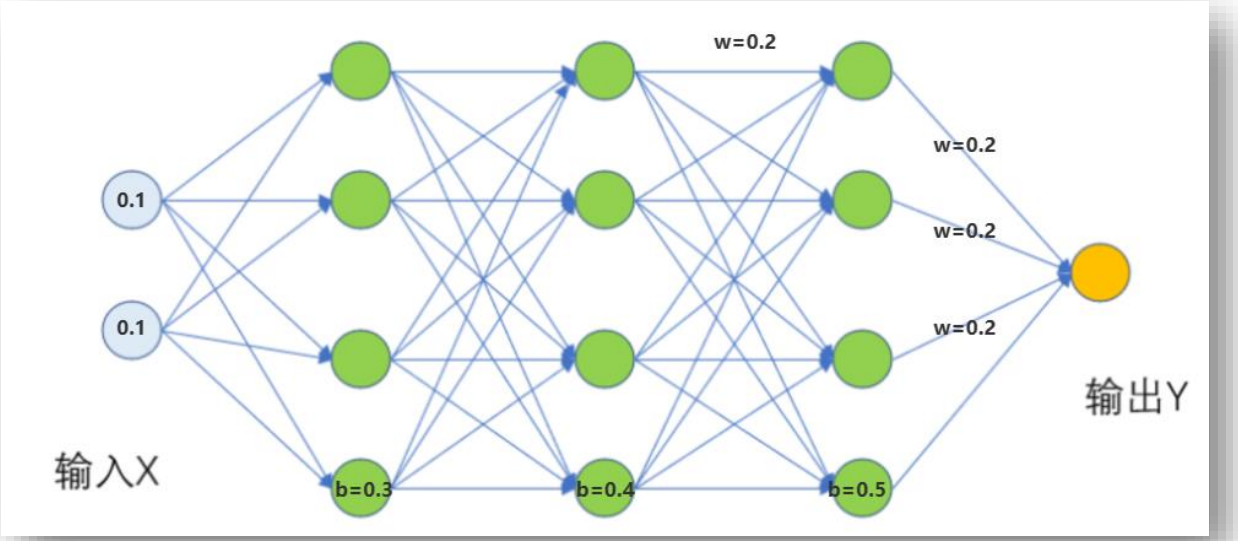

大模型微调方法

大模型微调方法可分为：有监督微调和无监督微调

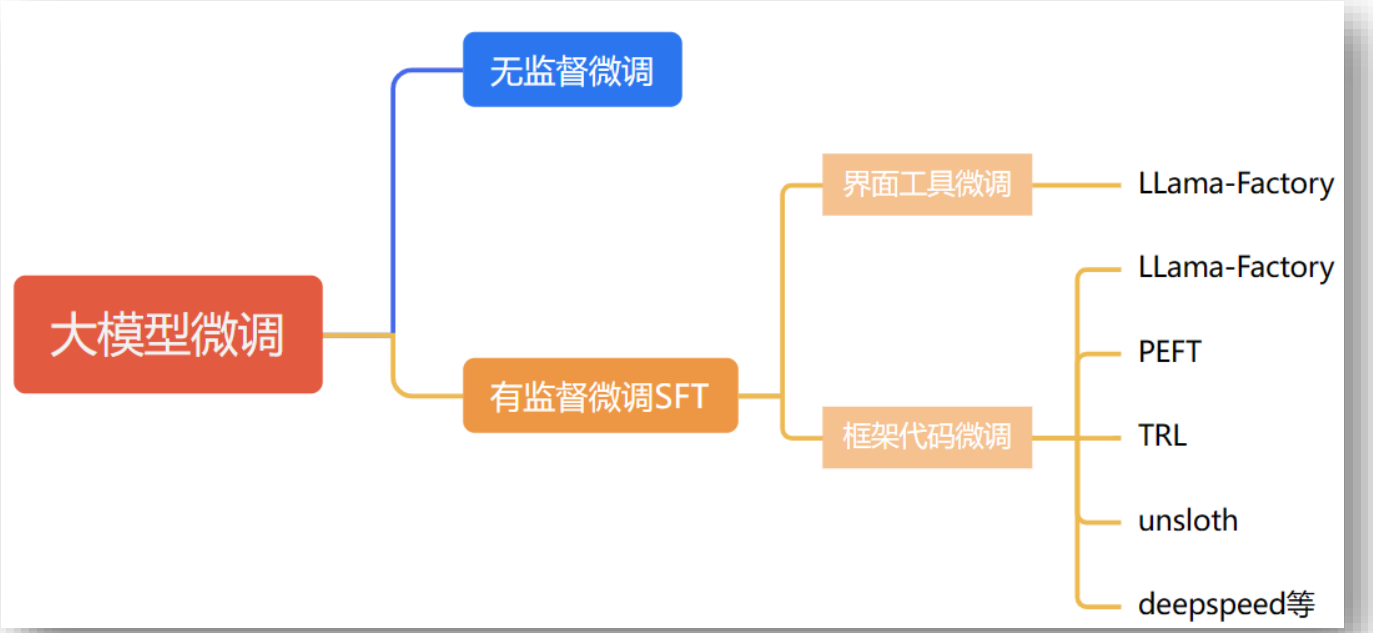

大模型微调方法

无监督微调

无监督微调是一种无需标签的训练方式，主要依赖于模型自身的能力来理解数据。

通常用于大型模型的预训练过程，如BERT、GPT等。

有监督微调（Supervised fine-tuning，SFT）

有监督微调需要标签数据，模型权重会根据与真实标签的差异进行调整。通过这个微调过程，模型能够捕捉到标签数据中特定于某一任务的模式和特点。使得模型更加精确，更好地适应某一特定任务。

通常是基于预训练模型在垂直领域上的参数调整。

大模型微调一般特指有监督微调。

大模型微调方法

有监督微调（Supervised fine-tuning，SFT）

根据微调对整个预训练模型的调整程度，微调可以分为全量微调和部分微调两个方法：

1. **全量微调（Full Fine-tuning）**：全微调是指对整个预训练模型进行微调，包括所有的模型参数。在这种方法中，预训练模型的所有层和参数都会被更新和优化，以适应目标任务的需求。
2. **部分微调（Repurposing）**：部分微调是指在微调过程中只更新模型的顶层或少数几层，而保持预训练模型的底层参数不变。这种方法的目的是在保留预训练模型的通用知识的同时，通过微调顶层来适应特定任务。

在部分微调中，更普遍的做法是**参数高效微调（Parameter-Efficient Fine Tuning， PEFT）**。

大模型微调方法

有监督微调（Supervised fine-tuning，SFT）

常见的有监督微调技术如下：

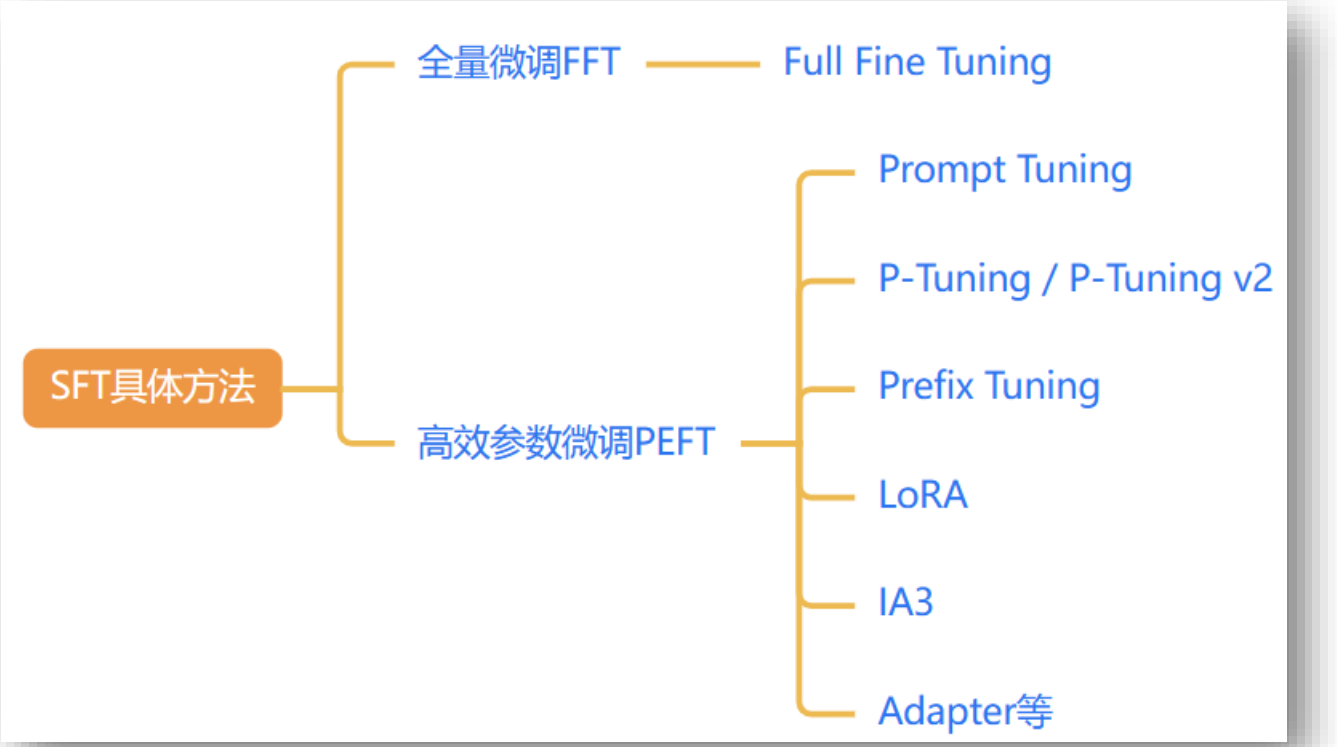

大模型微调方法

硬件要求

进行大规模有监督微调的硬件要求取决于所使用的模型大小和数据量。以下是一些基本的要求和建议：

- **CPU和RAM ：至少一个多核CPU，至少需要16G RAM。**
- **GPU和显存：至少一个高性能GPU，显存至少8G。**

具体需求可能会根据模型的大小、训练数据的大小和复杂性以及模型的性能目标而有所不同。对于非常大的模型和大规模数据集，可能还需要分布式训练和优化，这可能需要更多的计算资源。

大模型微调方法

模型准备

ModelScope魔搭社区是一个以模型为中心的开源社区平台，汇集了多种领域的优质模型，包括视觉、语音、自然语言处理、多模态等AI主要领域，覆盖了超过60个不同的任务类型。

所有上架的模型都经过专家筛选和效果验证，并且都是开源代码或开放使用的，无需魔法。

Thanks!